

Prueba técnica para BD – Brandon Jimenez Rodriguez

Instrucciones de ejecución e inspección:

Les comparto el archivo README.pdf y el comprimido PROYECTO.zip con el código fuente del proyecto en caso de no poder descargar el código fuente desde github. Cabe señalar que no es estrictamente necesario ejecutar la aplicación para la evaluación, pero sí se requiere el código fuente para su revisión técnica.

Para la restauración de la base de datos (en caso de ser requerida), encontrarán las siguientes alternativas dentro del directorio etl/DATA/:

- idtest_db_dump.dump: Archivo de respaldo principal en formato personalizado de PostgreSQL (pg_restore).
- idtest_db_dump.sql: Respaldo en texto plano SQL.
- Archivos .csv: Datos limpios e individuales para la carga masiva directa por tabla.

1. Dado el archivo .csv que contiene los datos de 4 entidades (CDMX, Morelos, Edo. México y Querétaro) Diseñar una DB que contenga toda la información de manera que pueda ser accesible, organizada e indexada.

a) Diseñar el MER de la DB para almacenar los datos.

El archivo **DDL_IDTEST.sql** (se encuentra en la raíz del proyecto) contiene las instrucciones DDL para la creación del esquema con la lógica definida.

b) Se puede programar un script que haga la carga masiva al schema (puede usarse Python, PHP o el lenguaje de su gusto o su dominio)

El script generado con el nombre **etl_down_up.py** (ubicado en etl/etl_down_up.py) contiene la lógica en python que:

1. Genera 3 archivos csv apartir del csv de insumo BD_PRUEBA.csv
2. Hace la carga masiva de datos a la BD tomando como insumo los 3 csv nuevos del punto anterior.
3. Finalmente se generan dos archivos el .dump y .sql , cualquiera de estos 2 se puede usar para montar la BD.

Los archivos de salida se generan en etl/DATA/, en el archivo PROYECTO.zip o al clonar desde github ya vienen generados estos archivos.

c) Diseñar los SP que ayuden a aprovisionar los resultados que solvente los siguientes reportes:

a. Listado del top 10 de colonias que tengan mayor población femenina de 15 a 49 años.

1. Hallazgo Técnico y Diagnóstico de Datos
- Nota sobre los datos censales (Diagnóstico):

Al analizar la fuente original BD_PRUEBA_.csv, se identificó que las métricas demográficas (como p_15a49_f y p_total) contienen valores consolidados a nivel Entidad Federativa repetidos en cada asentamiento geográfico. Por ejemplo, registros individuales de colonias en la CDMX muestran la cifra del estado completo (8,851,080 en p_total y 2,495,688 en p_15a49_f). Aplicar una agregación directa SUM() sobre esta estructura genera un producto cartesiano que infla los totales a decenas de millones.

2. Propuesta(Lógica del Stored Procedure)

Propuesta de Implementación :

Asumiendo que la columna fbi_p_15a49_f representa el total ya calculado de población femenina de 15 a 49 años por asentamiento/colonia, la lógica correcta consiste en obtener la métrica escalar por colonia mediante MAX(fbi_p_15a49_f) (para evitar duplicaciones en caso de joins con múltiples geografías) y ordenar de manera descendente para extraer el Top N configurado en el parámetro p_limit.

Archivo ubicado en : dql/sp_a.sql

b. Datos absolutos y porcentuales por entidad (estado) de población con alguna limitación/discapacidad específica.

Hallazgo Técnico y Criterio de Agregación Metodológico

Se asume que el suministro de datos cuenta con las métricas demográficas (p_total, pcon_lim, pclim_*) precalculadas y consolidadas a nivel Entidad Federativa (Estado).

Por esta razón, se utiliza la función de agregación MAX() agrupada por estado, evitando la duplicidad o sobreconteo (fan-out) que ocurriría al aplicar SUM() sobre las distintas geometrías/colonias asociadas a una misma entidad.

Archivo ubicado en : dql/sp_b.sql

c. Datos absolutos en total por entidad de los datos del diccionario de las columnas 10,11,12,22 y 26

Hallazgo Técnico y Criterio de Agregación Metodológico

Se aplica MAX() asumiendo valores consolidados a nivel Entidad Federativa. En caso de consultar la información con granularidad a nivel localidad, colonia o AGEb, correspondería utilizar la agregación SUM().

Archivo ubicado en : dql/sp_b.sql

Nota: al revisar los datos, puedo notar que los valores vienen consolidados por entidad federativa, no vienen consolidados por municipio. Construí los Sps tomando en cuenta que vienen consolidados por entidad federativa excepto el inciso A.

Revisando datos similares en el sitio oficial del INEGI:

https://www.inegi.org.mx/programas/ccpv/2020/#Datos_abiertos

veo que los datos si deberían venir consolidados por municipio y no por entidad federativa.

**Adicionalmente agrego capturas de la aplicación web en el navegador:
home:**

Sp inciso A:


En este caso como ya sabemos que los datos vienen consolidados por entidad federativa y no por municipio. Construí el SP suponiendo que los datos vienen correctamente consolidados por municipio lo que hace que las graficas y los valores de las mismas sean los mismos.

PL/pgSQL SP + Chart.js

Colonia	ID Municipio	Estado	Población Femenina (15a49)
Fabrica Maria	68	México	4291585
Izcalli Chamapa	58	México	4291585
Electricistas Locales	107	México	4291585
Palacio	58	México	4291585
Jacarandas	107	México	4291585
Rancheria Las Lomas	88	México	4291585
Buenos Aires	91	México	4291585
Granjas Independencia C	34	México	4291585
San Juan Bosco 2	13	México	4291585
Highland Park	38	México	4291585

Requiere desagregación en origen

Candidate	Votes
Fabrica Maria	1,000
Izcalli Chamapa	1,000
Electricistas Locales	1,000
Palacio	1,000
Jacarandas	1,000
Rancheria Las Lomas	1,000
Buenos Aires	1,000
Granjas Independencia C	1,000
San Juan Bosco 2	1,000



Código SQL del Stored Procedure (sp_a.sql)

PostgreSQL / PL/pgSQL

```
CREATE OR REPLACE PROCEDURE IDTEST.SP_GET_FEMALE_POPULATION(  
    OUT p_status_code INT,  
    OUT p_status_message VARCHAR,  
    INOUT p_refcursor REFCURSOR DEFAULT 'ref_top10_female',  
    IN p_limit INT DEFAULT 10      -- Parámetro de entrada con default 10  
)  
LANGUAGE plpgsql  
AS $$  
DECLARE  
    v_state TEXT;  
    v_msg TEXT;  
    v_detail TEXT;  
BEGIN  
    -- 1. Inicialización de variables de control  
    p_status_code := 0;  
    p_status_message := 'Operación ejecutada con éxito.';  
  
    -- 2. Apertura del cursor dinámico usando COALESCE para mayor seguridad si p_limit viene explícitamente como NULL  
    OPEN p_refcursor FOR  
        SELECT  
            g.cvc_nomgeo          AS colonia,  
            g.cbi_cve_mun        AS municipio_num,  
            e.cvc_nom_ent        AS estado,  
            MAX(c.fbi_p_15a49_f) AS total_poblacion_femenina_15a49 -- Asumiendo que esta columna contiene el precalculo por cada colonia.  
        FROM IDTEST.FID_POPULATION_CENSUS c  
        INNER JOIN IDTEST.CID_GEOGRAPHY g  
            ON c.fbk_cvegeo = g.cck_cvegeo  
        INNER JOIN IDTEST.CID_STATE e  
            ON g.cfk_cve_ent = e.cck_cve_ent  
        WHERE LOWER(TRIM(g.cvc_nomgeo)) NOT IN ('sin nombre', 'sin nombre (en construccion)', 'ninguno', '')  
            AND g.cvc_nomgeo IS NOT NULL  
        GROUP BY  
            g.cvc_nomgeo,  
            g.cbi_cve_mun,  
            e.cvc_nom_ent  
        ORDER BY  
            total_poblacion_femenina_15a49 DESC  
        LIMIT COALESCE(p_limit, 10);  
  
EXCEPTION  
    WHEN OTHERS THEN  
        -- Captura de diagnósticos y pila de error  
        GET STACKED DIAGNOSTICS  
            v_state = RETURNED_SQLSTATE,  
            v_msg = MESSAGE_TEXT,  
            v_detail = PG_EXCEPTION_DETAIL;  
  
        -- Formato de respuesta de error  
        p_status_code := -1;  
        p_status_message := FORMAT('Error [%s]: %s. Detalle: %s', v_state, v_msg, COALESCE(v_detail, 'Sin detalle adicional'));  
  
        RAISE WARNING 'Excepción capturada en SP_GET_FEMALE_POPULATION: %', p_status_message;  
END;  
$$;
```

Sp inciso B:



```
localhost:8000/census/inciso-b/

Código SQL del Stored Procedure (sp_b.sql)

PostgreSQL / PL/pgSQL

CREATE OR REPLACE PROCEDURE IDTEST.SP_GET_DISABILITY_BY_STATE(
    OUT p_status_code INT,
    OUT p_status_message VARCHAR,
    INOUT p_refcursor REFCURSOR DEFAULT 'ref_disability_state'
)
LANGUAGE plpgsql
AS $$
DECLARE
    v_state TEXT;
    v_msg TEXT;
    v_detail TEXT;
BEGIN
    p_status_code := 0;
    p_status_message := 'Operación ejecutada con éxito.';

    -- Se asume agregación previa a nivel entidad; se usa MAX() para extraer el valor escalar único.
    OPEN p_refcursor FOR
    SELECT
        e.cvc_nom_ent AS estado,
        MAX(c.fbi_p_total) AS poblacion_total,
        -- Totales absolutos por condición
        MAX(c.fbi_pcon_lim) AS total_con_discapacidad,
        MAX(c.fbi_pclim_mot) AS dis_motriz,
        MAX(c.fbi_pclim_vis) AS dis_visual,
        MAX(c.fbi_pclim_aud) AS dis_auditiva,
        MAX(c.fbi_pclim_leng) AS dis_lenguaje,
        MAX(c.fbi_pclim_men) AS dis_mental,
        -- Porcentajes sobre la población total del estado
        ROUND((MAX(c.fbi_pcon_lim)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_con_discapacidad,
        ROUND((MAX(c.fbi_pclim_mot)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_motriz,
        ROUND((MAX(c.fbi_pclim_vis)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_visual,
        ROUND((MAX(c.fbi_pclim_aud)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_auditiva,
        ROUND((MAX(c.fbi_pclim_leng)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_lenguaje,
        ROUND((MAX(c.fbi_pclim_men)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_mental
    FROM IDTEST.FID_POPULATION_CENSUS c
    INNER JOIN IDTEST.CID_GEOGRAPHY g
        ON c.ffk_cvegeo = g.cck_cvegeo
    INNER JOIN IDTEST.CID_STATE e
        ON g.cfk_cve_ent = e.cck_cve_ent
    GROUP BY
        e.cck_cve_ent,
        e.cvc_nom_ent
    ORDER BY
        pct_con_discapacidad DESC;

EXCEPTION
    WHEN OTHERS THEN
        GET STACKED DIAGNOSTICS
            v_state = RETURNED_SQLSTATE,
            v_msg = MESSAGE_TEXT,
            v_detail = PG_EXCEPTION_DETAIL;

    p_status_code := -1;
    p_status_message := FORMAT('Error [%s]: %s. Detalle: %s', v_state, v_msg, COALESCE(v_detail, 'Sin detalle adicional'));

    RAISE WARNING 'Excepción capturada en SP_GET_DISABILITY_BY_STATE: %', p_status_message;
END;
$$;
```

Sp inciso C:

← → ↺ 🌐 localhost:8000/census/inciso-c/ ⭐ 📄 ⬇️ 🔍 ⋮

Censo INEGI SQL Platform

Inicio Inciso A Inciso B Inciso C

C. Datos absolutos para las columnas 10, 11, 12, 22 y 26 PL/pgSQL SP + Chart.js

Detalle de Métricas Demográficas Absolutas

Nombre Entidad	Población Total	Población Total Masculina	Población Femenina ≥ 5 años	Población Total ≥ 15 años
México	15175862	7396986	6982253	10635400
Distrito Federal	8851080	4233783	4214622	6715516
Querétaro	1827937	887188	846346	1269931
Morelos	1777227	858588	829973	1262274

Top 10 Entidades: Población Total vs. Población Masculina

Entidad	Población Total	Población Masculina
México	15.18M	7.40M
Distrito Federal	8.85M	4.23M
Querétaro	1.83M	0.89M
Morelos	1.78M	0.86M

Grupos Demográficos Específicos por Estado (Top 8)

Entidad	Población Femenina ≥ 5 años	Población Total ≥ 15 años
México	6.98M	10.64M
Distrito Federal	4.21M	6.72M
Querétaro	0.85M	1.27M
Morelos	0.83M	1.26M


Hallazgo Técnico y Criterio de Agregación Metodológico

Se aplica **MAX()** asumiendo valores consolidados a nivel Entidad Federativa. En caso de consultar la información con granularidad a nivel localidad, colonia o AGEB, correspondería utilizar la agregación **SUM()**.

Código SQL del Stored Procedure (sp_c.sql)

PostgreSQL / PL/pgSQL

```
CREATE OR REPLACE PROCEDURE IDTEST.SP_GET_DEMOGRAPHICS(  
    OUT p_status_code INT,
```



d. Insumos necesarios:

Para integrar la capa espacial a la base de datos se requieren los siguientes componentes:

A. Archivos vectoriales (Shapefiles/ GeoJSON/ GeoPackage):

Geometría de entidades federativas (límite estatal): Polígonos de los 32 estados.

Geometría de localidades/colonias/AGEB: Polígonos o Puntos de las localidades censales con su llave geográfica única (CVEGEO).

B. Sistema de referencia espacial (SRID/EPSSG)

Para México, el estándar oficial es **EPSSG:6372** (WGS 84 / ITRF2008 / UTM) o **EPSSG:4326** (WGS 84 – Latitud/Longitud).

C. Extensión Espacial Activada

en este caso ya la tenemos activada en la bd postgresql .

Proceso para la integración:

1. Confirmar que la extensión esta activada.

2. Cargar los archivos de datos geograficos a la BD usando herramientas como ogr2ogr

Ejemplo usando ogr2ogr desde la terminal

```
ogr2ogr -f "PostgreSQL" PG:"host=localhost dbname=mi_bd user=postgres password=secret"
"conjunto_de_datos/00ent.shp" -ln idtest.cid_state_geom -a_srs "EPSG:6372" -t_srs
"EPSG:4326"
```

3. Estandarización e indexación de la columna geometrica.

Convertir la columna de geometría a tipo GEOMETRY(Geometry, 4326) y agregar un índice sobre la misma columna tipo GEOMETRY, en el caso de nuestro DDL ya se incluyo esta columna CGO_GEOM en la tabla IDTEST.CID_GEOGRAPHY , al igual que el índice espacial ya esta creado.

-- Ejemplo:

-- Agregar columna de geometría si se trabaja sobre una tabla existente

```
ALTER TABLE IDTEST.CID_GEOGRAPHY ADD COLUMN IF NOT EXISTS CGO_GEOM
GEOMETRY(Geometry, 4326);
```

-- Crear índice espacial GiST (imprescindible para desempeño)

```
CREATE INDEX IX2_CID_GEOGRAPHY_GEOM ON IDTEST.CID_GEOGRAPHY USING
GIST(CGO_GEOM);
```

4. adicionalmente se puede hacer una validación y reparacion de topología.

Verificar que las geometrías cargadas sean válidas (sin polígonos auto-intersecados o huecos en las fronteras).

-- Corregir geometrías no válidas automáticamente

```
UPDATE IDTEST.CID_GEOGRAPHY
```

```
SET geom = ST_MakeValid(geom)
```

```
WHERE NOT ST_IsValid(geom);
```

Nota: de esta forma ya podemos consultar los datos espaciales y crear algunas vistas útiles.