

Prueba tecnica para BD – Brandon Jimenez Rodriguez

Para ejecutar el proyecto es indispensable clonar el repositorio desde github:

git clone <https://github.com/brandhi/idtest.git>

y consultar el archivo **README.md**

En caso de no poder ingresar al proyecto en github les comparto el archivo **README.pdf** y **PROYECTO.zip** con el codigo fuente necesario para ejecutar el proyecto.

1. Dado el archivo .csv que contiene los datos de 4 entidades (CDMX, Morelos, Edo. México y Querétaro) Diseñar una DB que contenga toda la información de manera que pueda ser accesible, organizada e indexada.

a) Diseñar el MER de la DB para almacenar los datos.

El archivo **DDL_IDTEST.sql** contiene las instrucciones DDL para la creación del esquema con la logica definida.

b) Se puede programar un script que haga la carga masiva al schema (puede usarse Python, PHP o el lenguaje de su gusto o su dominio)

El scrip generado con el nombre **etl_down_up.py** contiene la logia en python que:

1. Genera 3 archivos csv apartir del csv de insumo **BD_PRUEBA.csv**
2. Hace la carga masiva de datos a la BD tomando como insumo los 3 csv nuevos del punto anterior.
3. Finalmente se generan dos archivos el .dump y .sql , cualquiera de estos 2 se puede usar para montar la BD.

Adjunto el archivo **DATA.zip** en el correo en caso de no poder acceder al proyecto en github. En github se encuentran en **etl/DATA/**

c) Diseñar los SP que ayuden a aprovisionar los resultados que solvente los siguientes reportes:

a. Listado del top 10 de colonias que tengan mayor población femenina de 15 a 49 años.

1. Hallazgo Técnico y Diagnóstico de Datos

Nota sobre los datos censales (Diagnóstico):

Al analizar la fuente original **BD_PRUEBA.csv**, se identificó que las métricas demográficas (como **p_15a49_f** y **p_total**) contienen valores consolidados a nivel Entidad Federativa repetidos en cada asentamiento geográfico. Por ejemplo, registros individuales de colonias en la CDMX muestran la cifra del estado completo (8,851,080 en **p_total** y 2,495,688 en **p_15a49_f**). Aplicar una agregación directa **SUM()** sobre esta estructura genera un producto cartesiano que infla los totales a decenas de millones.

2. Propuesta(Lógica del Stored Procedure)

Propuesta de Implementación :

Asumiendo que la columna fbi_p_15a49_f representa el total ya calculado de población femenina de 15 a 49 años por asentamiento/colonia, la lógica correcta consiste en obtener la métrica escalar por colonia mediante MAX(fbi_p_15a49_f) (para evitar duplicaciones en caso de joins con múltiples geografías) y ordenar de manera descendente para extraer el Top N configurado en el parámetro p_limit.

Archivo :

github : dql/sp_a.sql

adjunto en el correo sp_a.sql

b. Datos absolutos y porcentuales por entidad (estado) de población con alguna limitación/discapacidad específica.

Hallazgo Técnico y Criterio de Agregación Metodológico

Se asume que el suministro de datos cuenta con las métricas demográficas (p_total, pcon_lim, pclim_*) precalculadas y consolidadas a nivel Entidad Federativa (Estado).

Por esta razón, se utiliza la función de agregación MAX() agrupada por estado, evitando la duplicidad o sobreconteo (fan-out) que ocurriría al aplicar SUM() sobre las distintas geometrías/colonias asociadas a una misma entidad.

Archivo :

github : dql/sp_b.sql

adjunto en el correo sp_b.sql

c. Datos absolutos en total por entidad de los datos del diccionario de las columnas 10,11,12,22 y 26

Hallazgo Técnico y Criterio de Agregación Metodológico

Se aplica MAX() asumiendo valores consolidados a nivel Entidad Federativa. En caso de consultar la información con granularidad a nivel localidad, colonia o AGEB, correspondería utilizar la agregación SUM().

Archivo :

github : dql/sp_c.sql

adjunto en el correo sp_c.sql

Nota: al revisar los datos, puedo notar que los valores vienen consolidados por entidad federativa, no vienen consolidados por municipio. Construí los Sps tomando en cuenta que vienen consolidados por entidad federativa excepto el inciso A.

Revisando datos similares en el sitio oficial del INEGI:

https://www.inegi.org.mx/programas/ccpv/2020/#Datos_abiertos

veo que los datos si deberían venir consolidados por municipio y no por entidad federativa.

**Adicionalmente agrego capturas de la aplicación web con django en el navegador:
home:**

localhost:8000/census/

Censo INEGI SQL Platform

Inicio Inciso A Inciso B Inciso C

Métricas Demográficas y Análisis Censal

Consola de consulta ejecutiva sobre los Stored Procedures PostgreSQL del esquema IDTEST.

Inciso A

Población Femenina (15 a 49 años)

Consulta del Top N de asentamientos/colonias. Análisis del hallazgo técnico sobre métricas consolidadas repetidas a nivel entidad.

SP Involucrado:

SP_GET_FEMALE_POPULATION

Explorar Vista →

Inciso B

Métricas de Discapacidad por Estado

Desglose de limitaciones (motriz, visual, auditiva, lenguaje, mental) y porcentajes relativos agrupados por Entidad Federativa.

SP Involucrado:

SP_GET_DISABILITY_BY_STATE

Explorar Vista →

Inciso C

Datos Demográficos Absolutos

Análisis comparativo de las columnas censales 10, 11, 12, 22 y 26 (población total, masculina y subgrupos por edad).

SP Involucrado:

SP_GET_DEMOGRAPHICS

Explorar Vista →

Archivos de Carga ETL y Dumps de Base de Datos (./etl/DATA/)

5 Archivos disponibles

Descarga los insumos procesados por el pipeline ETL ('et_down_up.py') y los respaldos completos generados para PostgreSQL:

cid_state.csv

cid_geography.csv

fid_population_census.csv

idtest_db_dump.dump (Custom Format)

idtest_db_dump.sql (Plain Text)

Sp inciso A:

En este caso como ya sabemos que los datos vienen consolidados por entidad federativa y no por municipio. Construí el SP suponiendo que los datos vienen correctamente consolidados por municipio lo que hace que las graficas y los valores de las mismas sean los mismos.

PL/pgSQL SP + Chart.js

Colonia	ID Municipio	Estado	Población Femenina (15a49)
Fabrica Maria	68	México	4291585
Izcalli Chamapa	58	México	4291585
Electricistas Locales	107	México	4291585
Palacio	58	México	4291585
Jacarandas	107	México	4291585
Rancheria Las Lomas	88	México	4291585
Buenos Aires	91	México	4291585
Granjas Independencia C	34	México	4291585
San Juan Bosco 2	13	México	4291585
Highland Park	38	México	4291585

Requiere desagregación en origen

Neighborhood	Number of Houses
Fabrica Maria	100
Izcalli Chamapa	100
Electricistas Locales	100
Palacio	100
Jacarandas	100
Rancheria Las Lomas	100
Buenos Aires	100
Granjas Independencia C	100
San Juan Bosco 2	100


4291585

Población Femenina (15-49)

COLONIAS MOSTRADAS

GRANULARIDAD DE LA FUENTE

Comparativa por Colonia (Top N)



Distribución de Registros en Muestra

Hallazgo Técnico de Datos:

Al analizar la fuente original `BD_PRUEBA.csv`, se identificó que las métricas demográficas (como `p_15a49_f` y `p_total`) contienen valores consolidados a nivel Entidad Federativa repetidos en cada asentamiento geográfico. Por ejemplo, registros individuales de colonias en la CDMX muestran la cifra del estado completo (8,851,080 en `p_total` y 2,495,688 en `p_15a49_f`). Aplicar una agregación directa `SUM()` sobre esta estructura genera un producto cartesiano que infla los totales a decenas de millones.

Propuesta:

Asumiendo que la columna `fbi_p_15a49_f` representa el total ya calculado de población femenina de 15 a 49 años por asentamiento/colonia, la lógica correcta consiste en obtener la métrica escalar por colonia mediante `MAX(fbi_p_15a49_f)` (para evitar duplicaciones en caso de joins con múltiples geografías) y ordenar de manera descendente para extraer el Top N configurado en el parámetro `p_limit`.

Código SQL del Stored Procedure (sp_a.sql)

PostgreSQL / PL/pgSQL

Código SQL del Stored Procedure (sp_a.sql)

PostgreSQL / PL/pgSQL

```
CREATE OR REPLACE PROCEDURE IDTEST.SP_GET_FEMALE_POPULATION(  
    OUT p_status_code INT,  
    OUT p_status_message VARCHAR,  
    INOUT p_refcursor REFCURSOR DEFAULT 'ref_top10_female',  
    IN p_limit INT DEFAULT 10      -- Parámetro de entrada con default 10  
)  
LANGUAGE plpgsql  
AS $$  
DECLARE  
    v_state TEXT;  
    v_msg TEXT;  
    v_detail TEXT;  
BEGIN  
    -- 1. Inicialización de variables de control  
    p_status_code := 0;  
    p_status_message := 'Operación ejecutada con éxito.';  
  
    -- 2. Apertura del cursor dinámico usando COALESCE para mayor seguridad si p_limit viene explícitamente como NULL  
    OPEN p_refcursor FOR  
    SELECT  
        g.cvc_nomgeo          AS colonia,  
        g.cbi_cve_mun         AS municipio_num,  
        e.cvc_nom_ent         AS estado,  
        MAX(c.fbi_p_15a49_f)  AS total_poblacion_femenina_15a49 -- Asumiendo que esta columna contiene el precalculo por cada colonia.  
    FROM IDTEST.FID_POPULATION_CENSUS c  
    INNER JOIN IDTEST.CID_GEOGRAPHY g  
        ON c.ffk_cvegeo = g.cck_cvegeo  
    INNER JOIN IDTEST.CID_STATE e  
        ON g.cfk_cve_ent = e.cck_cve_ent  
    WHERE LOWER(TRIM(g.cvc_nomgeo)) NOT IN ('sin nombre', 'sin nombre (en construccion)', 'ninguno', '')  
        AND g.cvc_nomgeo IS NOT NULL  
    GROUP BY  
        g.cvc_nomgeo,  
        g.cbi_cve_mun,  
        e.cvc_nom_ent  
    ORDER BY  
        total_poblacion_femenina_15a49 DESC  
    LIMIT COALESCE(p_limit, 10);  
  
EXCEPTION  
    WHEN OTHERS THEN  
        -- Captura de diagnósticos y pila de error  
        GET STACKED DIAGNOSTICS  
            v_state = RETURNED_SQLSTATE,  
            v_msg = MESSAGE_TEXT,  
            v_detail = PG_EXCEPTION_DETAIL;  
  
        -- Formato de respuesta de error  
        p_status_code := -1;  
        p_status_message := FORMAT('Error [%s]: %s. Detalle: %s', v_state, v_msg, COALESCE(v_detail, 'Sin detalle adicional'));  
  
        RAISE WARNING 'Excepción capturada en SP_GET_FEMALE_POPULATION: %', p_status_message;  
END;  
$$;
```

Sp inciso B:



Código SQL del Stored Procedure (sp_b.sql)

PostgreSQL / PL/pgSQL

```
CREATE OR REPLACE PROCEDURE IDTEST.SP_GET_DISABILITY_BY_STATE(  
    OUT p_status_code INT,  
    OUT p_status_message VARCHAR,  
    INOUT p_refcursor REFCURSOR DEFAULT 'ref_disability_state'  
)  
LANGUAGE plpgsql  
AS $$  
DECLARE  
    v_state TEXT;  
    v_msg TEXT;  
    v_detail TEXT;  
BEGIN  
    p_status_code := 0;  
    p_status_message := 'Operación ejecutada con éxito.';  
  
    -- Se asume agregación previa a nivel entidad; se usa MAX() para extraer el valor escalar único.  
    OPEN p_refcursor FOR  
    SELECT  
        e.cvc_nom_ent AS estado,  
        MAX(c.fbi_p_total) AS poblacion_total,  
        -- Totales absolutos por condición  
        MAX(c.fbi_pcon_lim) AS total_con_discapacidad,  
        MAX(c.fbi_pclim_mot) AS dis_motriz,  
        MAX(c.fbi_pclim_vis) AS dis_visual,  
        MAX(c.fbi_pclim_aud) AS dis_auditiva,  
        MAX(c.fbi_pclim_leng) AS dis_lenguaje,  
        MAX(c.fbi_pclim_men) AS dis_mental,  
        -- Porcentajes sobre la población total del estado  
        ROUND((MAX(c.fbi_pcon_lim)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_con_discapacidad,  
        ROUND((MAX(c.fbi_pclim_mot)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_motriz,  
        ROUND((MAX(c.fbi_pclim_vis)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_visual,  
        ROUND((MAX(c.fbi_pclim_aud)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_auditiva,  
        ROUND((MAX(c.fbi_pclim_leng)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_lenguaje,  
        ROUND((MAX(c.fbi_pclim_men)::NUMERIC / NULLIF(MAX(c.fbi_p_total), 0)) * 100, 2) AS pct_mental  
    FROM IDTEST.FID_POPULATION_CENSUS c  
    INNER JOIN IDTEST.CID_GEOGRAPHY g  
        ON c.ffk_cvegeo = g.cck_cvegeo  
    INNER JOIN IDTEST.CID_STATE e  
        ON g.cfk_cve_ent = e.cck_cve_ent  
    GROUP BY  
        e.cck_cve_ent,  
        e.cvc_nom_ent  
    ORDER BY  
        pct_con_discapacidad DESC;  
  
EXCEPTION  
    WHEN OTHERS THEN  
        GET STACKED DIAGNOSTICS  
            v_state = RETURNED_SQLSTATE,  
            v_msg = MESSAGE_TEXT,  
            v_detail = PG_EXCEPTION_DETAIL;  
  
    p_status_code := -1;  
    p_status_message := FORMAT('Error [%s]: %s. Detalle: %s', v_state, v_msg, COALESCE(v_detail, 'Sin detalle adicional'));  
  
    RAISE WARNING 'Excepción capturada en SP_GET_DISABILITY_BY_STATE: %', p_status_message;  
END;  
$$;
```

Sp inciso C:

Censo INEGI

SQL Platform

Inicio

Inciso A

Inciso B

Inciso C

C. Datos absolutos para las columnas 10, 11, 12, 22 y 26

PL/pgSQL SP + Chart.js

Detalle de Métricas Demográficas Absolutas

Nombre Entidad	Población Total	Población Total Masculina	Población Femenina ≥ 5 años	Población Total ≥ 15 años
México	15175862	7396986	6982253	10635400
Distrito Federal	8851080	4233783	4214622	6715516
Querétaro	1827937	887188	846346	1269931
Morelos	1777227	858588	829973	1262274

Top 10 Entidades: Población Total vs. Población Masculina

Entidad	Población Total	Población Masculina
México	15.18M	7.40M
Distrito Federal	8.85M	4.23M
Querétaro	1.83M	0.89M
Morelos	1.78M	0.86M

Grupos Demográficos Específicos por Estado (Top 8)

Entidad	Población Femenina ≥ 5 años	Población Total ≥ 15 años
México	6.98M	10.64M
Distrito Federal	4.21M	6.72M
Querétaro	0.85M	1.27M
Morelos	0.83M	1.26M


Hallazgo Técnico y Criterio de Agregación Metodológico

Se aplica **MAX()** asumiendo valores consolidados a nivel Entidad Federativa. En caso de consultar la información con granularidad a nivel localidad, colonia o AGEB, correspondería utilizar la agregación **SUM()**.

Código SQL del Stored Procedure (sp_c.sql)

PostgreSQL / PL/pgSQL

```
CREATE OR REPLACE PROCEDURE IDTEST.SP_GET_DEMOGRAPHICS(  
  OUT p_status_code INT,
```



d. Insumos necesarios:

Para integrar la capa espacial a la base de datos se requieren los siguientes componentes:

A. Archivos vectoriales (Shapefiles/ GeoJSON/ GeoPackage):

Geometría de entidades federativas (límite estatal): Polígonos de los 32 estados.

Geometría de localidades/colonias/AGEB: Polígonos o Puntos de las localidades censales con su llave geográfica única (CVEGEO).

B. Sistema de referencia espacial (SRID/EPSSG)

Para México, el estándar oficial es **EPSSG:6372** (WGS 84 / ITRF2008 / UTM) o **EPSSG:4326** (WGS 84 – Latitud/Longitud).

C. Extensión Espacial Activada

en este caso ya la tenemos activada en la bd postgresql .

Proceso para la integración:

1. Confirmar que la extensión esta activada.

2. Cargar los archivos de datos geograficos a la BD usando herramientas como ogr2ogr

Ejemplo usando ogr2ogr desde la terminal

```
ogr2ogr -f "PostgreSQL" PG:"host=localhost dbname=mi_bd user=postgres password=secret"
"conjunto_de_datos/00ent.shp" -ln idtest.cid_state_geom -a_srs "EPSG:6372" -t_srs
"EPSG:4326"
```

3. Estandarización e indexación de la columna geometrica.

Convertir la columna de geometría a tipo GEOMETRY(Geometry, 4326) y agregar un índice sobre la misma columna tipo GEOMETRY, en el caso de nuestro DDL ya se incluyo esta columna CGO_GEOM en la tabla IDTEST.CID_GEOGRAPHY , al igual que el índice espacial ya esta creado.

-- Ejemplo:

-- Agregar columna de geometría si se trabaja sobre una tabla existente

```
ALTER TABLE IDTEST.CID_GEOGRAPHY ADD COLUMN IF NOT EXISTS CGO_GEOM
GEOMETRY(Geometry, 4326);
```

-- Crear índice espacial GiST (imprescindible para desempeño)

```
CREATE INDEX IX2_CID_GEOGRAPHY_GEOM ON IDTEST.CID_GEOGRAPHY USING
GIST(CGO_GEOM);
```

4. adicionalmente se puede hacer una validación y reparacion de topología.

Verificar que las geometrías cargadas sean válidas (sin polígonos auto-intersecados o huecos en las fronteras).

-- Corregir geometrías no válidas automáticamente

```
UPDATE IDTEST.CID_GEOGRAPHY
```

```
SET geom = ST_MakeValid(geom)
```

```
WHERE NOT ST_IsValid(geom);
```

Nota: de esta forma ya podemos consultar los datos espaciales y crear algunas vistas útiles.